


MC896 · PROCESSAMENTO DE LINGUAGEM NATURAL 2026

Grafo de Conhecimento a partir de Casos Clínicos

Extração de entidades e relações com técnicas clássicas de NLP.

NLP-Projeto 1 · Equipe: Mateus Farha, Lucas Lembo, Gustavo Rodrigues, Gabriela Coppo, João Azeredo · github.com/jrsbr/NLP-Projeto1

Pipeline em 5 etapas



Duas tabelas: nós e arestas

Nós

node_id · case_id · type · label · attributes

10 tipos: Patient, History, Symptom, Diagnosis, Exam, ExamResult, Finding, Treatment, AnatomicalSite, Unit

Arestas

edge_id · case_id · source_id · target_id · relation

15 relações: HAS_HISTORY, PRESENTS_WITH, UNDERWENT_EXAM, UNDERWENT_TREATMENT, HAS_RESULT, HAS_UNIT, DIAGNOSED_WITH, SUPPORTS, TREATED_BY, CONFIRMS, EXCLUDES, REVEALS, LOCATED_IN, TARGETS, PERFORMED_ON

O critério: o que vira nó e o que fica como atributo

Três testes, aplicados ao exame de troponina do caso PMC7102447_01 , que mediu 0.04 ng/mL :

Teste	Pergunta	ng/mL	0.04
Reuso	reaparece em outros casos e deve apontar pro mesmo nó?	sim	não, é coincidência numérica
Consulta	a pergunta sobre ele se responde percorrendo aresta?	sim, "quais exames usam esta unidade"	não, troponina > 0.03 é comparação
Identidade	existe fora do exame que o carrega?	sim	não

Por isso Unit virou nó compartilhado entre casos, e valor e faixa de referência ficaram como texto em attributes do ExamResult . Decompor tudo não é obrigatório: inflaria o grafo sem responder nenhuma pergunta nova.

As entidades Symptom, Diagnosis, Exam, Treatment e AnatomicalSite precisam ser encontradas no texto livre, sem LLM e sem NER estatístico. Como fazer isso?

Etapa 1: segmentação de sentenças

O que ela resolve

O caso chega como um parágrafo corrido. Toda regra que vem depois precisa de uma janela delimitada para decidir o que se relaciona com o quê: sem recorte, um sintoma do primeiro parágrafo seria ligado a um diagnóstico do último só por estarem no mesmo texto.

A granularidade escolhida: a sentença

Granularidade	Por que não
palavra	perde o contexto que dá sentido à relação
sentença	é onde o autor do relato agrupa um fato clínico completo
parágrafo ou caso inteiro	relaciona coisas que só estão perto por acaso

Como é feito

Uma expressão regular: pontuação final (. ! ?) seguida de espaço e de letra maiúscula ou abre parêntese. Sem tokenizador externo e sem download de modelo.

entrada	She underwent contrast enhanced computed tomography, demonstrating a 6cm cystic lesion between the stomach and body/tail of the pancreas (Fig 1). The patient was therefore referred for surgical resection.
saída	[1] She underwent contrast enhanced computed tomography, demonstrating a 6cm cystic lesion between the stomach and body/tail of the pancreas (Fig 1). [2] The patient was therefore referred for surgical resection.

O corpus tem 1.426 sentenças em 56 casos, uma média de 25,5 por caso.

Medical Subject Headings: vocabulário controlado da National Library of Medicine (EUA), usado para indexar artigos no PubMed.

Por que MeSH

- Sem uma taxonomia assim, seria necessário escrever à mão cinco listas de milhares de termos médicos.
- Público e sem licença, ao contrário de UMLS e SNOMED CT, que exigem cadastro e aprovação.
- Vocabulário já usado no dataset: `metadata.csv` traz `major_mesh_terms` por artigo, o que permite validar a extração contra anotação externa.
- Organizado em árvore por código (`TreeNumber`): um único arquivo cobre todos os 5 tipos, só trocando o prefixo do filtro.

Entidade	Ramo MeSH	Cobre
Symptom	C23	Sinais e sintomas
Diagnosis	C exceto C23	Doenças
Exam	E01	Procedimentos diagnósticos
Treatment	D + E02	Substâncias, drogas e procedimentos terapêuticos
AnatomicalSite	A	Anatomia

Por que reduzir o dicionário

Cada descritor do MeSH traz em média 8 ou 9 grafias do mesmo conceito, quase todas variação rara ou histórica. Somando tudo, são **265.700 termos**. Mantendo apenas o termo preferido de cada conceito, sobram **61.439**, uma redução de 4,3 vezes. O sinônimo de verdade sobrevive (`tympanometry` continua ao lado de `acoustic impedance tests`); o que morre é a variação de escrita.

A redução só importa por causa de uma das duas buscas

Busca	O que faz	O custo cresce com
exata	acha o termo escrito letra por letra igual	o tamanho do texto
tolerante	acha o termo com pequena variação de escrita	o tamanho do dicionário

A busca exata lê a sentença uma vez, com dicionário grande ou pequeno. A tolerante precisa comparar a palavra do texto contra os termos da lista, então cada termo a mais é trabalho a mais.

O que cada dicionário usa, e por quê

Dicionário	Termos	Busca	Motivo
<code>symptom</code>	2.137	exata + tolerante	lista pequena, a tolerante roda rápido
<code>exam</code>	1.329	exata + tolerante	lista pequena, a tolerante roda rápido
<code>anatomical_site</code>	3.061	exata + tolerante	lista pequena, a tolerante roda rápido
<code>diagnosis</code>	9.133	só exata	grande demais para a busca tolerante
<code>treatment</code>	26.765	só exata	grande demais para a busca tolerante

Nessas duas medidas 3 segundos por sentença, o que daria mais de uma hora nas 1.426 sentenças do corpus, então ficaram só com busca exata. Sem o corte do dicionário, as três pequenas seriam 4 vezes maiores e cairiam junto.

Busca exata: Aho-Corasick

O problema

São cerca de 42 mil termos nos cinco dicionários e 1.426 sentenças. Um `Ctrl+F` por termo daria aproximadamente 60 milhões de buscas.

O que é

Um autômato montado a partir de todos os termos do dicionário de uma vez. Ele organiza os termos numa árvore de letras, em que termos que começam igual compartilham o mesmo caminho:

```
(raiz)
├─ h → e → p → a → r → i → n          heparin
├─ c → o → r → o → n → a → r → y        coronary
└─ a → c → u → t → e → _ → c → o → r → o → n → a → r → y → _ → s...
                                           acute coronary syndrome
```

Como funciona

A sentença é lida **uma única vez**, letra por letra, andando na árvore. A posição atual na árvore resume quais termos ainda podem estar acontecendo ali. Ao fechar um caminho marcado, achou um termo. Quando a letra quebra o caminho, o autômato não volta ao início do texto: salta para o maior final do que já leu que ainda sirva de começo de outro termo, e é isso que garante a passada única.

O custo é proporcional ao tamanho do texto, **não** ao número de termos. É uma busca exata: só encontra o que está escrito letra por letra igual. Quando dois termos casam no mesmo trecho, vence o mais longo.

"...started immediately on **heparin** infusion for suspicion of **acute coronary syndrome**..." Aqui `acute coronary syndrome` vence `coronary`, que também casaria no mesmo trecho.

Busca tolerante: Damerau-Levenshtein e BK-tree

O que ela resolve

A busca exata perde variação leve de escrita. `heart-attack` no texto não casa com `heart attack` no dicionário, embora seja o mesmo conceito.

Distância de Damerau-Levenshtein

O número mínimo de edições para transformar uma palavra na outra. São quatro edições possíveis:

Edição	Exemplo
inserir uma letra	<code>anemia</code> para <code>anaemia</code>
remover uma letra	<code>oedema</code> para <code>edema</code>
substituir uma letra	<code>fibrosis</code> para <code>fibrasis</code>
trocar duas letras de posição	<code>edema</code> para <code>deema</code>

`heart-attack` e `heart attack` estão a distância 1: uma substituição.

BK-tree

Comparar a palavra do texto contra os 3.061 termos do dicionário, um por um, seria caro. A BK-tree organiza o dicionário pela distância entre os próprios termos, o que permite descartar galhos inteiros sem comparar com eles: se um termo está longe da consulta, tudo que está próximo dele também está.

Os limites que colocamos

- Aceita no máximo **1 edição**, então erro maior que isso só é recuperado pela busca exata.
- Olha janelas de **1 palavra**, porque o objetivo é erro de escrita e não frase parafraseada.
- Roda só em `symptom`, `exam` e `anatomical_site`, os três dicionários pequenos.

ExamResult: valor + unidade por regex

A lista de unidades

Um arquivo de texto, `units.txt`, com uma unidade por linha, curada à mão. São 50 no total; a amostra abaixo mostra 12:

mg/dL	IU/L	mmHg	cm
g/dL	ng/mL	bpm	mm
mmol/L	pg/mL	%	kg

Ela é escrita à mão e **sem** tolerância a erro de escrita, ao contrário dos gazetteers. O motivo é o tamanho: unidade é curta, então qualquer tolerância vira falso positivo fácil. Aceitar 1 edição em `L` de litro faria a letra casar com qualquer inicial solta no texto.


Regex dinâmico

O padrão não está escrito no código: é montado em tempo de execução a partir do arquivo. As unidades são ordenadas por tamanho decrescente, para `mg/dL` ganhar de `mg`, e viram alternativas de um mesmo grupo.

```
units.txt → ordena por tamanho, escapa cada símbolo, junta com |
            (?P<value>\d[\d,\.]*)\s*(?P<unit>mg/dL|mmol/L|ng/mL|mmHg|%|cm)\b
```

A vantagem é operacional: acrescentar uma unidade é editar uma linha do arquivo, sem tocar no código.

"Initial **troponin** was normal at **0.04 ng/mL**"



Nem toda substância é um tratamento

O problema


A lista de `Treatment` vem do ramo `D` do MeSH, "Chemicals and Drugs", que reúne toda substância química que existe. Ele não distingue **droga administrada** de **substância medida num exame**, porque para o MeSH as duas são só substâncias. Sem tratar isso, a frase "*hemoglobin was 9 g/dL*" produz no grafo "o paciente foi tratado com hemoglobina".

A solução ingênua não funciona

Separar à mão, dizendo que hemoglobina é exame e heparina é remédio. Falha porque a mesma substância é as duas coisas, às vezes no mesmo caso. Em `PMC9529523_01`:

"The patient was started on hydroxychloroquine 300 mg daily"	remédio , tem verbo de administração
"The serum hydroxychloroquine level was 1232.1 ng/ml"	exame , tem valor medido

Só o contexto distingue, então a decisão tem que olhar o texto ao redor.



Em `PMC5137649_01`, "*a **carcinoembryonic antigen (CEA) level of 12,476.5 ng/mL***" não tem verbo de administração e tem o número 16 caracteres depois: virou `Exam`.

Já encontramos tudo que o caso menciona, ou seja, já temos os nós do grafo. Mas eles ainda estão soltos. Como conectar?

Co-ocorrência e gatilho textual

Metade das arestas não precisa de regra

Toda entidade encontrada liga direto no paciente, e o tipo do nó já determina a relação: se achamos um sintoma no caso, o paciente apresenta aquele sintoma. Essa camada é automática e responde por PRESENTS_WITH , DIAGNOSED_WITH , UNDERWENT_EXAM , UNDERWENT_TREATMENT e HAS_HISTORY , justamente as arestas mais numerosas do grafo.

O problema real é a outra camada: ligar **entidade com entidade**. Aí não há nada óbvio a copiar, e é para isso que servem as duas ferramentas seguintes.

Co-ocorrência: descobre que existe ligação

A regra é: duas entidades na mesma sentença provavelmente se relacionam.

Nenhuma compreensão do texto está envolvida. A aposta é que a sentença é a unidade de assunto do relato, então o autor só escreveu duas coisas juntas porque elas têm a ver. É o que cria SUPPORTS , LOCATED_IN , PERFORMED_ON e TARGETS . Barato, funciona na maioria dos casos, e erra quando a sentença junta coisas por acaso.

Gatilho textual: descobre qual é a ligação, e o sinal dela

Co-ocorrência diz que há relação, mas não diz de que tipo. O gatilho é uma expressão do texto que resolve isso, e ele carrega também a polaridade, que é o que impede o grafo de afirmar o contrário do que o caso diz:

Gatilho no texto	Sinal	Relação criada
confirmed , consistent with , positive for	positivo	CONFIRMS
excluded , ruled out , no evidence of	negativo	EXCLUDES
showed , revealed , demonstrated	neutro	REVEALS

Uma sentença com "no evidence of malignancy" registra que o exame **descartou** o diagnóstico. Sem polaridade, viraria "o paciente tem malignidade". Há ainda gatilhos de outro uso: history of marca o que é passado clínico e não caso atual, e treated with e given marcam administração de droga.

As regras, uma por uma


Quando a sentença traz	O grafo recebe
history of X	X deixa de ser ocorrência atual e vira um nó History
exame sem valor numérico, com gatilho por perto	aresta CONFIRMS , EXCLUDES ou REVEALS para um diagnóstico já visto, ou um nó Finding com o texto cru quando nada bate no vocabulário
sintoma e diagnóstico juntos	Symptom SUPPORTS Diagnosis
tratamento depois de um diagnóstico	Diagnosis TREATED_BY Treatment
local anatômico e exame juntos	Exam PERFORMED_ON AnatomicalSite
local anatômico e diagnóstico juntos	Diagnosis LOCATED_IN AnatomicalSite
local anatômico e tratamento juntos	Treatment TARGETS AnatomicalSite

As três últimas são co-ocorrência pura: mudam de nome só porque o outro lado da ligação é um exame, um diagnóstico ou um tratamento.

Quase toda regra olha apenas a sentença. TREATED_BY é a exceção: ela guarda o último diagnóstico visto e liga a ele qualquer tratamento posterior, mesmo várias sentenças depois.

Um caso, do texto ao grafo


PMC7102447_01 · A 65-year-old male with a past medical history significant for hypertension, asthma, and minimally invasive bioprosthetic mitral valve replacement... presented with severe respiratory distress requiring emergent intubation.




As linhas tracejadas finas que saem do paciente são a camada automática: o tipo do nó já diz qual é a relação, sem precisar de regra. As linhas cheias são as inferidas pelas regras do slide anterior. Ao todo, 19 nós e 28 arestas neste caso.

56 casos, 1588 nós, 2054 arestas

NÓS POR TIPO



ARESTAS POR RELAÇÃO (TOP 10)



O que os números mostram

- **AnatomicalSite** é o tipo mais numeroso (399). Quase toda frase clínica menciona uma parte do corpo, e o ramo A do MeSH é o de cobertura mais generosa. É também o tipo com mais ruído, porque casa com sentidos fora do clínico.
- **UNDERWENT_EXAM** é a relação mais frequente (274). Isso reflete o gênero do texto: relato de caso é construído em cima da investigação diagnóstica, não do tratamento.
- **Co-ocorrência anatômica responde por 28% do grafo.** **PERFORMED_ON**, **TARGETS** e **LOCATED_IN** somam 583 das 2054 arestas, ou seja, mais de um quarto das ligações vem de proximidade no texto e não de evidência explícita.

Limitações conhecidas

- **O MeSH não foi criado para esta finalidade.** Ele existe para catalogar artigos do PubMed, e nós o usamos para tipar menções em texto clínico. Onde os dois propósitos não coincidem, a entidade pode sair classificada no tipo errado.
- **A cobertura de `Exam` tem buracos.** Nem todo exame comum tem descritor MeSH com o nome que o texto usa. O conceito de ultrassom endoscópico está catalogado como `endosonography`, então `endoscopic ultrasound` e a sigla `EUS`, que são as formas que o relato escreve, não casam com nada e o exame não entra no grafo.
- **Sobra ambiguidade em `Treatment`.** A reclassificação da substância só funciona quando o valor está colado no texto, dentro de 20 caracteres. *"hemoglobin was 9 g/dL"* é reconhecido; *"hemoglobin was low, and was later measured at 9 g/dL"* passa da janela e escapa.
- **Termos genéricos colidem com palavra comum.** Alguns descritores do MeSH são palavras corriqueiras do inglês, então *"a diagnosis of pneumonia was made"* criaria um nó de exame chamado "Diagnosis". Bloqueamos três desses à mão no código (`Diagnosis`, `Therapeutics` e `Pharmaceutical Preparations`), a partir dos falsos positivos que vimos rodando o pipeline. A lista foi curada olhando estes 56 casos, então em texto novo outros vão aparecer.

Como modelos de linguagem foram usados

- **Zero LLM na técnica de extração.** NER, valores e relações são 100% regra, dicionário e regex, sem nenhuma chamada a modelo de linguagem em tempo de execução.
- LLM usado para escrever partes do pipeline e integralmente usado para criar a interface de visualização dos grafos de conhecimento.
- LLM utilizada como mecanismo de consulta para os métodos de extração e os conceitos abordados no projeto.
- Revisão e formatação dos slides desta apresentação.

Obrigado

github.com/jrsbr/NLP-Projeto1